


# 2026\_0703\_현우\_계획안


## 1. Overall Architecture

### Overall Architecture

VLM-centric sequential navigation with direct action and trajectory execution



### VLM-Centric Sequential Decision Loop



우리는 RL-trained S2E를 local trajectory backbone으로 사용하고, VOCA-style target-context cues, current RGB observation, lightweight sparse navigation memory를 활용하는 VLM-centric sequential decision loop를 통해 high-level target을 S2E-compatible navigable floor-point goal\_xy로 지속적으로 생성·보정하는 generalized navigation framework를 제안한다.

## 2. 1차 목표 설계안

⇒ 먼저 S2E에 넣을 `goal_xy / waypoint` 를 만들어주는 VOCA-side 모듈을 독립적으로 구현하고 검증



"GPT와 대화를 하기 위한 예시 이미지"

### 2.1 목표 구조

High-level target + image + prompt + 상태 정보

↓

Improved VOCA / VLM reasoning module

↓

S2E에 넣을 refined waypoint 또는 local goal\_xy 생성

### • 2.1.1 Module I/O Definition

#### Input:

- target\_type: gps / object\_point / language / missing\_point
- high\_level\_target: 예) bathroom, toilet, GPS coordinate
- current\_rgb
- optional\_lookaround\_images
- current\_pose / heading
- current\_goal\_xy 또는 previous\_waypoint
- progress\_state: normal / low\_progress / blocked / repeated
- \_view / tracking\_loss
- memory\_summary: visited, failed, unexplored directions
- system\_prompt

#### Output:

- refined\_goal\_xy: [x, y]
- selected\_image\_point: [u, v] 또는 null
- action\_type: keep / refine / reselect / lookaround
- reasoning: 선택 이유
- confidence: high / medium / low

## 2.2 검증 대상

1. coarse GPS target이 들어왔을 때  
-> 현재 위치/heading 기준으로 더 적절한 local waypoint를 만들 수 있는가?
2. coarse object point가 들어왔을 때  
-> object 주변의 실제 주행 가능한 point로 보정할 수 있는가?
3. Tracking loss 또는 input point가 없는 경우  
-> VLM reasoning과 look-around로 새로운 후보 waypoint를 만들 수 있는가?
4. Deadlock / 막힘 / 반복 주행 상황  
-> 기존 방향을 버리고 다른 fine goal point를 제안할 수 있는가?

이걸 위해 단위 테스트셋을 만들어야 한다. 각 테스트 샘플마다 아래처럼 구성한다. prompt와 rule, 입력/출력 포맷만 잘 설계해서 우리가 원하는 reasoning과 waypoint refinement가 되는 지 먼저 검증한다.



## 2.3 단위 테스트셋 구성 및 평가 기준

각 케이스는 **Input / Expected Output / Pass Criteria** 기준으로 평가한다

### • 1차 검증의 범위와 가정

본 1차 검증에서는 S2E trajectory generation 성능 자체는 평가하지 않고, **S2E에 입력으로 줄 수 있는 refined goal\_xy를 Improved VOCA module이 안정적으로 생성·보정할 수 있는지를 검증한다.**

VLM은 별도 재학습 없이 기존 backbone model을 사용하며, prompt와 rule-based post-processing을 통해 output format과 waypoint selection을 제어한다. 따라서 본 단계의 핵심 deliverable은 S2E-compatible goal\_xy 생성 모듈, 단위 테스트셋, 평가 지표, 실패 케이스 분석이다.

### • 평가지표 정의표

| 평가 지표                         | 의미                                                               | 측정 방법                                                  | 관련 케이스                           |
|-------------------------------|------------------------------------------------------------------|--------------------------------------------------------|----------------------------------|
| <b>goal_xy validity rate</b>  | 생성된 goal_xy 가 S2E 입력으로 사용할 수 있고, 실제 주행 가능한 위치인지 평가               | 전체 샘플 중 유효한 goal_xy 가 생성된 비율                           | 전체 케이스                           |
| <b>waypoint success rate</b>  | 모델이 제안한 waypoint가 사람이 정의한 acceptable waypoint region 안에 들어가는지 평가 | refined goal_xy 가 정답 후보 영역 안에 있으면 success              | coarse GPS / coarse object point |
| <b>reasoning correctness</b>  | VLM의 reasoning이 현재 이미지, 목표, 상태 정보와 논리적으로 일치하는지 평가                | 사람이 reasoning을 correct / incorrect로 판정                 | 전체 케이스                           |
| <b>recovery success rate</b>  | tracking loss, deadlock, blocked 상황에서 새로운 유효 waypoint를 제안했는지 평가  | 실패 상황에서 기존 방향을 버리고 대체 waypoint를 제안하면 success           | tracking loss / deadlock         |
| <b>look-around efficiency</b> | 올바른 waypoint를 찾기 위해 필요한 관측 비용을 평가                                | waypoint 생성까지 사용한 look-around 횟수 또는 VLM call 수         | tracking loss / deadlock         |
| <b>progress gain</b>          | 보정된 waypoint가 목표 방향으로 실제 progress를 증가시키는지 평가                     | 기존 coarse waypoint 대비 목표까지의 거리 감소량 또는 이동 후 progress 비교 | coarse GPS / deadlock            |
| <b>failure repeat rate</b>    | 이전에 실패한 방향이나 waypoint를 반복 선택하는지 평가                               | 동일 실패 방향을 다시 선택한 비율                                    | deadlock / repeated navigation   |



**coarse GPS target이 들어왔을 때**

### • 목적

**“Coarse GPS waypoint를 실제 주행 가능한 local goal로 보정할 수 있는지 검증한다.”**

Habitat sim에서 말하는 coarse GPS target은 실제 위도/경도라기보다, 시뮬레이터 world 좌표계의 목표 위치로 받아오게 된다. Habitat의 PointGoal navigation은 기본적으로 “현재 위치 기준으로 목표까지의 상대 좌표, 즉  $\Delta x$ ,  $\Delta y$ 로 가라”는 형태라서, 우리가 원하는 **goal\_xy** 실험과 잘 맞는다. **Habitat episode에서 target position을 하나 정하고, agent의 현재 position과 heading을 이용해서 world goal → robot-local goal\_xy로 변환하는 과정을 검증한다.** 또한 “coarse”하게 만들고 싶다면 true target에 noise를 주거나, 욕실 전체 중심점처럼 대략적인 위치만 준다.

- **Input**

- Current **RGB** image
- (Optional) Look-around images
- Coarse **GPS** target
- Current robot **pose** (**GPS** / heading)
- System prompt

- **Expected Output**

- Refined local goal\_xy
- **VLM reasoning**  
(왜 이 방향을 선택했는지)

- **Pass Criteria**

- coarse **GPS**보다 주행 가능한 위치를 선택하는가
- 장애물을 피하는 방향을 선택하는가
- target 방향으로 progress가 증가하는가
- reasoning이 사람이 봐도 타당한가



**coarse object point가 들어왔을 때**

- **목적**

Coarse object point도 본질은 “object 위치 자체”가 아니라, 그 object에 접근하기 위한 navigable waypoint를 잘 고르는지 보는 것이다. 예를 들어 목표가 **욕실의 변기** 인데 coarse object point가 변기 중심이나 욕실 안쪽으로 찍혀 있으면, 로봇이 바로 그 점으로 가는 게 아니라 **욕실 문 앞, 문 안쪽 진입 지점, 변기 앞 접근 가능한 공간**처럼 실제 주행 가능한 지점으로 보정하는 것이다.

- Input

- Current RGB image
- Coarse object point
- System prompt

- Expected Output

- Refined local goal\_xy
- Semantic reasoning

- Pass Criteria

- object 근처의 navigable point를 선택하는가
- object 자체가 아닌 접근 가능한 위치를 선택하는가
- trajectory 생성이 가능한 위치인가



### Tracking loss 또는 input point가 없는 경우

- 목적

**“명확한 target point가 사라졌을 때도 VLM reasoning과 look-around를 통해 새로운 후보 waypoint를 생성할 수 있는지 검증한다.”**

Tracking loss 또는 input point가 없는 경우는 “명확한 waypoint가 사라졌을 때도 스스로 다음 후보 goal을 만들 수 있는가”를 보는 테스트이다. 예를 들어 목표가 욕실인데, 이전에 추적하던 욕실 방향 point를 잃었거나 detector/VLM이 더이상 object point를 못 주는 상황이면, Improved VOCA는 현재 RGB와 look-around view, memory를 보고 **가장 유망한 탐색 방향**을 다시 정해야 한다. 저 이미지 기준이면 로봇이 시작 방에 있고 target point가 없더라도, “일단 방 문을 나가 복도로 진입해야 한다”는 reasoning으로 문/복도 방향의 `local goal_xy`를 생성하면 성공이다.

- Input

- Current **RGB** image
- Optional look-around images
- High-level target: 예) `"bathroom", "toilet", "go to the bathroom"`
- Previous waypoint 또는 tracking history
- Tracking loss flag / input point missing flag
- System prompt

- Optional memory: 이전에 시도한 방향, 실패한 방향, 방문한 공간 정보

### • Expected Output

- 새롭게 제안된 refined local goal\_xy
- 선택한 방향 또는 image point
- Semantic reasoning  
예) "현재 target point는 없지만, 욕실에 도달하려면 먼저 방 문을 통해 복도로 나가야 한다."

### • Pass Criteria:

- input point가 없어도 멈추지 않고 새로운 waypoint를 제안하는가
- 현재 관측에서 주행 가능한 방향을 선택하는가
- target과 semantic하게 관련 있는 방향을 선택하는가
- 이전 실패 방향이나 반복 방향을 피하는가
- reasoning이 현재 이미지와 목표에 대해 타당한가

즉 이 케이스의 핵심은 object나 GPS point가 없어도 멈추지 않고, semantic cue와 공간 구조를 이용해 다음 navigable waypoint를 복구하는지 확인하는 것이다.



## Deadlock / 막힘 / 반복 주행 상황

### • 목적:

로봇이 같은 위치를 반복하거나, 막힌 방향으로 계속 이동하려고 할 때 기존 goal\_xy를 버리고 새로운 waypoint를 제안할 수 있는지 검증한다.

### • Input

- Current RGB image
- Optional look-around images
- High-level target: 예) "bathroom", "toilet"
- Current local goal\_xy
- Recent trajectory / action history
- Progress signal: low progress, repeated view, collision, blocked motion
- Optional memory: 이전에 실패한 방향, 이미 방문한 공간 정보
- System prompt

## • Expected Output

- 기존 `goal_xy`를 유지할지 또는 버릴지에 대한 판단
- 새롭게 보정된 `refined local goal_xy`
- 선택한 방향 또는 `image point`
- Semantic reasoning

예) "현재 방향은 막혀 있고 progress가 없으므로, 왼쪽 문을 통해 복도로 나가는 `waypoint`를 선택한다."

## • Pass Criteria:

- deadlock 또는 막힘 상황을 올바르게 인식하는가
- 실패한 방향을 반복해서 선택하지 않는가
- look-around 또는 memory를 활용해 대체 `waypoint`를 제안하는가
- 새 `goal_xy`가 현재 위치에서 주행 가능한 방향인가
- target 도달 가능성을 높이는 방향으로 보정되는가

## 2.4 유사 선행연구 조사

본 구조와 유사하게 VLM/LLM을 이용해 high-level target을 local waypoint 또는 navigation subgoal로 변환하는 연구가 있는지 조사한다.

특히 object goal을 직접 trajectory policy에 넣는 방식, VLM이 intermediate waypoint를 선택하는 방식, language/GPS/object target을 local goal로 변환하는 방식, deadlock recovery를 위해 VLM reasoning을 사용하는 방식을 중심으로 비교한다.

| 선행연구                            | 우리와 비슷한 부분                                                                                                                | 우리와 다른 부분                                                                                                 | 코드/신뢰성 기준                                                          | 체크 결과                |
|---------------------------------|---------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------|----------------------|
| <b>PixNav / Pixel-Navigator</b> | foundation model이 지정한 <b>pixel goal</b> 을 navigation skill로 연결함. 즉, visual target을 navigation input으로 바꾸는 구조가 우리와 가장 가깝음. | PixNav는 pixel goal 기반 navigation이고, 우리는 VLM reasoning 결과를 S2E가 받을 수 있는 <b>**local goal_xy**</b> 로 변환·보정함. | 논문과 코드/데모 공개가 확인됨. ( <a href="#">arXiv</a> )                       | <b>가장 중요하게 비교 필요</b> |
| <b>VLFM</b>                     | VLM을 이용해 target object와 관련된 semantic frontier를 선택함. Habitat ObjectNav에서 평                                                 | occupancy/depth 기반 frontier map을 사용함. 우리는 map/frontier가 아니라 S2E-compatible                                | 논문, Habitat 평가, real-world Spot 실험이 확인됨. ( <a href="#">arXiv</a> ) | <b>직접 비교 후보</b>      |



| 선행연구                                   | 우리와 비슷한 부분                                                                                                             | 우리와 다른 부분                                                                                        | 코드/신뢰성 기준                                                          | 체크 결과                                   |
|----------------------------------------|------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|--------------------------------------------------------------------|-----------------------------------------|
|                                        | 가하고 SOTA급 SPL을 보고함.                                                                                                    | <code>goal_xy</code> 를 직접 생성·보정함.                                                                |                                                                    |                                         |
| <b>LM-Nav</b>                          | LLM, CLIP, navigation policy를 조합해 language instruction을 navigation subgoal로 연결함.                                       | outdoor language landmark navigation 성격이 강하고, S2E용 local <code>goal_xy</code> refinement 구조는 아님. | 논문, code release, Colab 공개가 확인됨. ( <a href="#">arXiv</a> )         | <b>관련 구조 비교</b>                         |
| <b>VLMaps</b>                          | language goal을 3D spatial map에 grounding하여 navigation goal로 변환함.                                                       | dense/spatial map 기반이며, 우리는 lightweight sparse memory 와 local waypoint refinement를 목표로 함.        | 논문과 project page 공개가 확인됨. ( <a href="#">arXiv</a> )                | <b>map-based 비교군</b>                    |
| <b>History-Augmented VLM ObjectNav</b> | action history를 VLM prompt에 넣어 반복 행동을 줄이고, VLM-assisted waypoint generation을 사용함.                                      | frontier-based ObjectNav이며, S2E trajectory backbone에 넣을 <code>goal_xy</code> 를 생성·보정하는 구조는 아님.   | 2025 arXiv 논문, Habitat HM3D 평가 결과가 확인됨. ( <a href="#">arXiv</a> )  | <b>우리 memory/deadlock과 가장 가까운 최신 연구</b> |
| <b>NaVid</b>                           | RGB video history를 VLM에 넣어 next-step navigation decision을 생성함.<br>map/odom/depth 없이 navigation action을 예측한다는 점이 관련 있음. | end-to-end next action prediction 성격이고, 명시적으로 S2E용 local <code>goal_xy</code> 를 만드는 구조는 아님.      | 2024 arXiv, SOTA 성능 및 sim-to-real 결과 보고. ( <a href="#">arXiv</a> ) | <b>최신 SOTA 흐름 참고</b>                    |
| <b>Uni-NaVid</b>                       | 여러 embodied navigation task를 하나의 video-based VLA 모델로 통합함.                                                              | 대규모 학습 기반 VLA이고, 우리는 기존 VLM + rule/prompt 기반 goal adapter를 S2E 앞단에 붙이는 구조임.                      | 2024 arXiv, SOTA 성능 및 real-world 실험 보고. ( <a href="#">arXiv</a> )  | <b>SOTA trend 비교</b>                    |

| 선행연구           | 우리와 비슷한 부분                                                                                                           | 우리와 다른 부분                                                                               | 코드/신뢰성 기준                                                                  | 체크 결과                     |
|----------------|----------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------|----------------------------------------------------------------------------|---------------------------|
| <b>DyNaVLM</b> | dynamic viewpoint selection과 self-refining graph memory를 사용함. adaptive look-around와 sparse memory 측면에서 우리와 매우 관련 있음. | end-to-end VLM navigation framework이고, S2E-compatible waypoint generator로 패키징하는 구조는 아님. | 2025 arXiv, GOAT/ObjectNav 및 real-world test 보고. ( <a href="#">arXiv</a> ) | <b>최신 유사 구조로 주의 깊게 확인</b> |

### 3. TodoList

7월 안에 VOCA-side module과 unit test 검증까지 끝내고, S2E 연결은 그 다음 단계로 진행한다

#### TodoList

- 1주차: VLM-centric decision module 설계
  - VLM input/output JSON format 정의
  - action\_type 정의: navigate / look\_around / stop / reselect\_goal
  - deadlock, uncertainty, tracking loss 판단 기준을 prompt에 포함
  - ObjectNav에서 object-front navigable floor point를 선택하도록 prompt rule 작성
- 2주차: Sequential loop 및 direct action branch 구현
  - VLM output parser 구현
  - action\_type = navigate인 경우 Goal Adapter로 연결
  - action\_type = look\_around인 경우 S2E를 거치지 않고 제자리 회전 control로 연결
  - action\_type = stop인 경우 stop control로 연결
  - look-around 후 new RGB를 다시 VLM input으로 넣는 loop 구현
- 3주차: Lightweight sparse navigation memory 구현
  - past goal\_xy, selected image point, visited/blocked direction, trajectory outcome 저장
  - memory summary를 VLM input context로 제공
  - deadlock/repeated view 상황에서 memory 기반 reselect\_goal 동작 검증

□ 4주차: 단위 테스트셋 기반 검증 및 S2E 연결 준비

- coarse GPS / coarse object point / tracking loss / deadlock 테스트셋 구성
- goal\_xy validity, waypoint success rate, reasoning correctness, recovery success rate 계산
- 실패 케이스 분석 후 prompt/rule 수정
- 검증된 refined goal\_xy를 S2E input interface에 연결